# Optimal Control

Yola25

March 2026

## 0.1 动态规划原理与 HJB 方程的推导

考虑如下确定性控制系统：

$$\dot{x}(s) = f(s, x(s), u(s)), \qquad x(t) = x,$$

其中 $x(s) \in \mathbb{R}^n$ 表示系统状态，$u(s) \in \mathbb{R}^m$ 表示控制输入。给定初始时刻 $t$ 和初始状态 $x$，我们希望在所有可行控制 $u(\cdot)$ 中寻找一个最优控制，使系统总代价最小。总代价定义为

$$J_{t,x}(u(\cdot)) = \int_t^1 L(s, x(s), u(s))\, ds + \Psi(x(1)),$$

其中 $L(s, x, u)$ 称为**运行成本**（running cost），$\Psi(x(1))$ 称为**终端成本**（terminal cost）。

因此，最优控制问题可以表述为：

$$\inf_{u(\cdot)} J_{t,x}(u(\cdot)).$$

为了刻画从任意中间时刻和状态出发的最优代价，引入**价值函数**（value function）：

$$V(t, x) = \inf_{u(\cdot)} \left\{ \int_t^1 L(s, x(s), u(s))\, ds + \Psi(x(1)) \;\middle|\; x(t) = x \right\}.$$

价值函数的含义是：从时刻 $t$、状态 $x$ 出发，在未来所有可行控制中所能实现的**最小总代价**。因此，$V(t, x)$ 本身并不是一个再去最小化的对象，而是“最小总代价”这个量的函数化表达。

当 $t = 1$ 时，系统已经到达终点，因此价值函数满足终端条件

$$V(1, x) = \Psi(x).$$

动态规划的核心思想是 **Bellman 最优性原理**：一个整体最优策略，从任意中间时刻开始看，其余下部分仍然必须是最优的。对应到价值函数上，这一原理可写为：对于任意 $t \le r \le 1$，有

$$V(t, x) = \inf_{u(\cdot)} \left\{ \int_t^r L(s, x(s), u(s))\, ds + V(r, x(r)) \;\middle|\; x(t) = x \right\}.$$

这就是**动态规划原理**（dynamic programming principle, DPP）。

它的含义是：从 $(t, x)$ 出发到终点的最优总代价，可以拆成两部分：

1. 从 $t$ 到中间时刻 $r$ 的累计运行成本；
2. 从 $r$ 时刻的状态 $x(r)$ 出发到终点的最优剩余成本，即 $V(r, x(r))$。

因此，动态规划原理体现了一种**时间一致性**：整体最优可以递归地分解为局部最优与后续最优之和。

为了从动态规划原理得到偏微分方程形式，取

$$r = t + h,$$

其中 $h > 0$ 很小。由 DPP 得

$$V(t,x) = \inf_{u(\cdot)} \left\{ \int_t^{t+h} L(s, x(s), u(s))\, ds + V(t+h, x(t+h)) \;\middle|\; x(t) = x \right\}.$$

将 $V(t,x)$ 移到右侧，并除以 $h$，得到

$$0 = \inf_{u(\cdot)} \left\{ \frac{1}{h} \int_t^{t+h} L(s, x(s), u(s))\, ds + \frac{V(t+h, x(t+h)) - V(t,x)}{h} \right\}.$$

这一步正是从“递推关系”走向“微分关系”的关键。

下面令 $h \to 0$。为此，需要分别处理上式中的两项。

**第一项：运行成本的平均值**

由于区间 $[t, t+h]$ 很短，在适当连续性条件下有

$$\frac{1}{h} \int_t^{t+h} L(s, x(s), u(s))\, ds \to L(t, x, u), \qquad h \to 0.$$

**第二项：价值函数增量的展开**

假设价值函数 $V(t,x)$ 足够光滑，对 $V(t+h, x(t+h))$ 作一阶 Taylor 展开：

$$V(t+h, x(t+h)) = V(t,x) + \frac{\partial V}{\partial t}(t,x)\, h + \nabla_x V(t,x) \cdot (x(t+h) - x) + o(h).$$

另一方面，由状态方程

$$\dot{x}(t) = f(t, x, u)$$

可得

$$x(t+h) - x = f(t,x,u)\, h + o(h).$$

代入上式，得到

$$V(t+h, x(t+h)) - V(t,x) = \frac{\partial V}{\partial t}(t,x)\, h + \nabla_x V(t,x) \cdot f(t,x,u)\, h + o(h).$$

两边除以 $h$，可得

$$\frac{V(t+h, x(t+h)) - V(t,x)}{h} = \frac{\partial V}{\partial t}(t,x) + \nabla_x V(t,x) \cdot f(t,x,u) + o(1).$$

将上述两项的极限代回动态规划关系，并令 $h \to 0$，可得

$$0 = \inf_u \left\{ L(t,x,u) + \frac{\partial V}{\partial t}(t,x) + \nabla_x V(t,x) \cdot f(t,x,u) \right\}.$$

由于 $\frac{\partial V}{\partial t}(t,x)$ 与 $u$ 无关，可写为

$$\frac{\partial V}{\partial t}(t,x) + \inf_{u\in\mathbb{R}^m}\{L(t,x,u) + \nabla_x V(t,x)\cdot f(t,x,u)\} = 0.$$

这就是 **Hamilton–Jacobi–Bellman 方程**，简称 **HJB 方程**。结合终端条件

$$V(1,x) = \Psi(x),$$

便得到一个带终端条件的非线性偏微分方程问题。

为了使表达更紧凑，引入 Hamiltonian：

$$H(t,x,p) = \inf_{u\in\mathbb{R}^m}\{L(t,x,u) + p\cdot f(t,x,u)\}.$$

令

$$p = \nabla_x V(t,x),$$

则 **HJB 方程可以写成更紧凑的形式**：

$$\frac{\partial V}{\partial t}(t,x) + H\big(t,x,\nabla_x V(t,x)\big) = 0, \qquad V(1,x) = \Psi(x).$$

HJB 方程的意义不仅在于给出价值函数的演化规律，更重要的是它能够导出最优控制的反馈形式。若 $V$ 是 HJB 方程的足够光滑解，并且极小值可以达到，则最优反馈控制 $u^*(t,x)$ 满足

$$u^*(t,x) = \arg\min_{u\in\mathbb{R}^m}\{L(t,x,u) + \nabla_x V(t,x)\cdot f(t,x,u)\}.$$

这说明：一旦求得价值函数 $V(t,x)$，就可以通过在 Hamiltonian 中取极小，恢复出最优控制律。

因此，从思想上说，**HJB 方程就是动态规划原理的无穷小极限形式**。动态规划原理是“全局的最优递推关系”，而 HJB 方程则是“局部的微分表达”。

尽管如此，HJB 方程仍然是最优控制理论中最核心的方程之一，因为它把一个“在所有控制轨道上做优化”的问题，转化成了一个“求解价值函数满足的偏微分方程”的问题。一旦该方程能够求解，最优值与最优反馈控制都可以随之得到。

**动态规划原理与 HJB 方程中优化变量的区别**

在动态规划原理（dynamic programming principle, DPP）中，价值函数满足

$$V(t,x) = \inf_{u(\cdot)}\left\{\int_t^r L(s,x(s),u(s))\,ds + V(r,x(r)) \,\middle|\, x(t) = x\right\},$$

其中优化变量为整个控制函数 $u(\cdot)$，即 $u:[t,r]\to\mathbb{R}^m$。因此该问题属于函数空间上的优化问题，是一个无限维优化问题。

相比之下，由动态规划原理在无穷小时间区间上的展开可得到 Hamilton–Jacobi–Bellman（HJB）方程：

$$\frac{\partial V}{\partial t}(t,x) + \inf_{u\in\mathbb{R}^m}\{L(t,x,u) + \nabla_x V(t,x)\cdot f(t,x,u)\} = 0.$$

在该方程中，优化变量仅为当前时刻的控制值 $u\in\mathbb{R}^m$，属于有限维优化问题。

这种差异来源于：在从 DPP 推导 HJB 方程时，仅考虑无穷小时间区间 $[t,t+h]$，在一阶近似下控制函数 $u(s)$ 可由其当前值 $u(t)$ 近似表示，从而将原本对整个控制轨迹的优化，转化为对当前控制变量的点值优化。因此，可以将这一转化理解为：从全局路径空间上的无限维优化问题，转化为局部时间上的有限维优化问题。

## 0.2 随机最优控制

**随机过程与随机微分方程的基本概念** 概率论研究的是随机现象的数学描述。现代概率论建立在**概率空间**的概念之上。一个概率空间记为

$$(\Omega, \mathcal{F}, \mathbb{P}),$$

其中 $\Omega$ 表示样本空间，$\mathcal{F}$ 表示定义在 $\Omega$ 上的 $\sigma$-代数，$\mathbb{P}$ 表示定义在 $(\Omega, \mathcal{F})$ 上的概率测度。

一个 $\mathbb{R}^n$-值**随机向量**可以看作一个从样本空间到状态空间的可测映射

$$x : \Omega \to \mathbb{R}^n.$$

类似地，一个 $\mathbb{R}^n$-值**随机过程**是一个按时间参数索引的随机变量族，通常记为

$$\{x(t)\}_{t\in[0,T_f]},$$

其中每个 $x(t)$ 都是从 $\Omega$ 到 $\mathbb{R}^n$ 的可测映射。若随机过程的样本路径关于时间连续，则称其为具有连续样本路径的随机过程。在扩散过程的讨论中，样本空间常可理解为连续路径空间

$$\Omega = C([0, T_f], \mathbb{R}^n).$$

在扩散过程的研究中，最基本也最重要的随机过程是**布朗运动**，也称为 **Wiener 过程**。它是刻画连续随机扰动的基本模型，也是构造随机微分方程的核心噪声来源。记一个标准 Wiener 过程为 $w(t)$，则由其诱导的概率测度称为 **Wiener 测度**。在随机控制和扩散过程理论中，Wiener 过程提供了描述微观随机扰动如何影响宏观动力学行为的基础框架。

**随机微分方程** Wiener 过程本身不仅是一个重要的随机模型，更常作为驱动噪声出现在随机动力系统中。连续时间下最常见的一类随机模型是**随机微分方程**（stochastic differential equation, SDE）：

$$dx(t) = f(t, x(t))\, dt + \sigma(t, x(t))\, dw(t), \qquad x(0) = x_0, \quad \text{a.s.}$$

其中：

- $f(t, x)$ 为漂移项（drift term），描述系统的确定性演化；
- $\sigma(t, x)$ 为扩散项（diffusion term），描述噪声对系统的作用强度；
- $dw(t)$ 表示由 Wiener 过程产生的随机增量，常被视为白噪声的积分形式；
- “a.s.” 表示 almost surely，即“几乎处处成立”。

在适当条件下，上述 SDE 存在解。按照解的构造方式与依赖关系，通常可以区分**强解**与**弱解**。

强解要求解过程 $x(\cdot)$ 在给定的概率空间以及给定的 Wiener 过程 $w(\cdot)$ 上构造出来，并且对噪声的历史具有因果依赖关系。换言之，强解强调：在固定噪声驱动下，解是适应于该噪声滤过的信息过程。因此，强解通常需要对系数函数 $f, \sigma$ 施加较强的正则性假设。

弱解则允许同时改变概率空间和 Wiener 过程本身，只要求存在某个概率结构，使得过程满足给定的随机微分方程。弱解的存在条件通常比强解更弱，因此在随机控制与随机分析中具有重要地位。虽然弱解不一定保留强解那样的路径因果构造性质，但其适用范围更广，是理论研究中的有力工具。

**线性随机微分方程及其显式解** 对于线性动力系统，其对应的随机微分方程可写为

$$dx(t) = A(t)x(t)\,dt + B(t)\,dw(t), \qquad x(0) = x_0.$$

这类线性 SDE 在适当条件下总是存在唯一解，并且可以显式写成

$$x(t) = \Phi(t,0)x_0 + \int_0^t \Phi(t,\tau)B(\tau)\,dw(\tau),$$

其中 $\Phi(t,s)$ 为系统的**状态转移矩阵**，满足

$$\frac{\partial}{\partial t}\Phi(t,s) = A(t)\Phi(t,s), \qquad \Phi(s,s) = I,$$

这里 $I$ 表示单位矩阵。

这一表示式具有清晰的物理含义：第一项

$$\Phi(t,0)x_0$$

对应于无噪声情形下初值在确定性线性系统中的传播；第二项

$$\int_0^t \Phi(t,\tau)B(\tau)\,dw(\tau)$$

则表示随机噪声在状态转移矩阵作用下对系统状态的累积影响。因此，线性 SDE 的解可以理解为“确定性演化 + 随机扰动响应”的叠加。

## 0.3 随机最优控制问题背景

随机最优控制研究在随机扰动存在的情况下，如何通过选择控制策略，使系统行为在某种意义下最优。其基本对象是带控制输入的随机微分方程（stochastic differential equation, SDE）：

$$dx(t) = f(t,x(t),u(t))\,dt + \sigma(t,x(t),u(t))\,dw(t), \quad x(0) = x_0, \tag{1}$$

其中：

- $x(t) \in \mathbb{R}^n$ 为系统状态；
- $u(t) \in \mathbb{R}^m$ 为控制输入；
- $w(t)$ 为标准布朗运动；
- $f$ 与 $\sigma$ 分别表示漂移项与扩散项。

**可允许控制与 Markov 策略** 称控制策略 $u(t)$ 为**可允许的（admissible）**，如果在该控制下系统存在（弱）解，并且 $u(t)$ 对状态过程是适应的（adapted）。

在实际问题中，通常考虑 **Markov 反馈控制**：

$$u(t) = \alpha(t, x(t)), \tag{2}$$

即控制仅依赖当前时刻和当前状态，而不显式依赖历史路径。

**优化目标** 随机最优控制的目标是在所有可允许控制中，最小化如下期望型代价泛函：

$$J(u) = \mathbb{E}\left[\int_0^T L(t, x(t), u(t))\, dt + \Psi(x(T))\right], \tag{3}$$

其中：

- $L$ 为运行代价（running cost）；
- $\Psi$ 为终端代价（terminal cost）。

由于系统具有随机性，优化目标是代价的期望值。

定义**价值函数（value function）**：

$$V(t, x) = \inf_u \mathbb{E}\left[\int_t^T L(s, x(s), u(s))\, ds + \Psi(x(T)) \,\middle|\, x(t) = x\right]. \tag{4}$$

其含义为：在时刻 $t$ 处于状态 $x$ 时，从当前出发所能达到的最小期望总代价。

价值函数满足**动态规划原理（Dynamic Programming Principle, DPP）**：

$$V(t, x) = \inf_u \mathbb{E}\left[\int_t^r L(s, x(s), u(s))\, ds + V(r, x(r)) \,\middle|\, x(t) = x\right], \tag{5}$$

对任意 $0 \le t \le r \le T$ 成立。

该原理体现了最优性的递归结构：整体最优可分解为局部最优与未来最优之和。

此外，当 $u^*$ 为最优控制时，有过程

$$\int_0^t L(s, x(s), u^*(s))\, ds + V(t, x(t)) \tag{6}$$

为一个鞅（martingale）。

令 $r = t + h$，并令 $h \to 0$，结合 Itô 公式，可形式推导出 **Hamilton–Jacobi–Bellman（HJB）方程**：

$$\begin{aligned}\frac{\partial V}{\partial t}(t, x) + \inf_{u \in \mathbb{R}^m} \Big\{ & L(t, x, u) + f(t, x, u) \cdot \nabla V(t, x) \\ & + \frac{1}{2}\mathrm{tr}\big[\sigma(t, x, u)\sigma(t, x, u)^\top \nabla^2 V(t, x)\big] \Big\} = 0.\end{aligned} \tag{7}$$

这是一个**二阶非线性偏微分方程**，其中二阶项来源于随机扰动（Itô 修正项）。

定义 Hamiltonian：

$$H(t, x, p, G) = \inf_{u \in \mathbb{R}^m} \left\{ L(t, x, u) + f(t, x, u) \cdot p + \frac{1}{2}\mathrm{tr}(\sigma\sigma^\top G) \right\}. \tag{8}$$

则 HJB 方程可写为：

$$\frac{\partial V}{\partial t} + H\left(t, x, \nabla V, \nabla^2 V\right) = 0, \tag{9}$$

配合终端条件

$$V(T, x) = \Psi(x). \tag{10}$$

一旦求得价值函数 $V(t,x)$，最优控制可由如下极小化条件给出：

$$u^*(t,x) = \arg\min_{u \in \mathbb{R}^m} \left\{ L(t,x,u) + \nabla V(t,x) \cdot f(t,x,u) + \frac{1}{2}\mathrm{tr}(\sigma\sigma^\top \nabla^2 V(t,x)) \right\}. \tag{11}$$

**与确定性最优控制的区别**

- **系统模型：**
  - 确定性：$\dot{x} = f(t,x,u)$；
  - 随机：$dx = f\,dt + \sigma\,dw$。
- **优化目标：**
  - 确定性：直接最小化路径代价；
  - 随机：最小化期望代价。
- **HJB 方程：**
  - 确定性：一阶 PDE；
  - 随机：二阶 PDE（含扩散项）。

引入控制的本质目的是：

- 引导系统达到期望状态；
- 抵抗随机扰动带来的不确定性；
- 在性能与控制代价之间取得最优平衡。

在随机系统中，控制策略本质上是一种**反馈机制**，用于在噪声环境下持续修正系统演化方向。